

PoC AI Assistant

Εισαγωγή

Η παρούσα εργασία αφορά την ανάπτυξη ενός Proof of Concept (PoC) συστήματος τεχνητής νοημοσύνης, με στόχο την υποστήριξη των εργαζομένων μιας ασφαλιστικής εταιρείας στην αναζήτηση πληροφοριών σχετικά με τις εσωτερικές πολιτικές και διαδικασίες του οργανισμού.


Περιγραφή του Προβλήματος

Σε καθημερινή βάση, ο υπάλληλος της εκάστοτε εταιρείας καλείται να διαχειριστεί έναν τεράστιο όγκο δεδομένων. Οι αλληλεπιδράσεις με πελάτες, ο φόρτος της εργασίας καθώς και η απομνημόνευση της δυναμικής πολιτικής του οργανισμού, καθιστούν το έργο του ιδιαίτερα δύσκολο. Αυτό έχει ως αποτέλεσμα την καθυστέρηση στην εξυπηρέτηση και την πτώση της αποδοτικότητας. Για να διορθώσουμε αυτό το πρόβλημα, στοχεύουμε στην δημιουργία ενός υποστηρικτικού εργαλείου, το οποίο θα επιλύει οποιαδήποτε απορία προκύπτει σχετικά με την πολιτική και τους κανονισμούς της εταιρείας, ανεξαρτήτως τόπου και χρόνου. Θα δημιουργήσουμε μια πλατφόρμα στην οποία ο χρήστης θα μπορεί να συνομιλεί με έναν βοηθό, ώστε να λαμβάνει καθοδήγηση για το πώς να διαχειριστεί την τρέχουσα κατάσταση. Το προτεινόμενο σύστημα αξιοποιεί τεχνολογίες τεχνητής νοημοσύνης ώστε να αναζητά γρήγορα τις κατάλληλες πληροφορίες με βάση τις πολιτικές της εταιρείας και να παρέχει τεκμηριωμένες απαντήσεις στον υπάλληλο.


Διαδικασία Επίλυσης

Κατά την ανάπτυξη του συστήματος, αντιμετωπίσα διάφορες ενδιαφέρουσες προκλήσεις. Η πρώτη, ήταν πώς θα πρέπει ο βοηθός να επεξεργαστεί τα δεδομένα που του παρέχονται, με στόχο να μπορεί με ευκολία να τα κατανοήσει ώστε να δώσει την κατάλληλη απάντηση. Για την αντιμετώπιση της πρόκλησης αυτής, υλοποίησα μία διαδικασία προεπεξεργασίας (ingestion), κατά την οποία κάθε έγγραφο διασπάται σε μικρότερα επικαλυπτόμενα τμήματα. Στη συνέχεια, κάθε τμήμα αποθηκεύεται σε μια βάση, μαζί με δεδομένα όπως το έτος, η σελίδα και το αρχείο προέλευσης. Με αυτόν τον τρόπο, το σύστημα ανακτά μόνο τα πιο σχετικά αποσπάσματα για κάθε ερώτημα, επιτρέποντας στο μοντέλο να βασίζεται τις απαντήσεις του αποκλειστικά σε τεκμηριωμένα στοιχεία των πολιτικών, βελτιώνοντας τόσο την ακρίβεια όσο και την αξιοπιστία των αποτελεσμάτων.

Μία ακόμη σημαντική πρόκληση που συνάντησα ήταν η δημιουργία του ίδιου του μοντέλου τεχνητής νοημοσύνης. Για την αντιμετώπιση αυτής της πρόκλησης υλοποιήθηκε μια agentic αρχιτεκτονική με χρήση του LangGraph, η οποία οργανώνει τη λειτουργία του βοηθού σε διακριτά στάδια (κόμβους). Κάθε στάδιο αναλαμβάνει μια συγκεκριμένη εργασία, όπως η ανάλυση του ερωτήματος και η παραγωγή της τελικής απάντησης. Παράλληλα, ενσωματώθηκε μηχανισμός διαχείρισης μνήμης, ώστε ο βοηθός να διατηρεί το ιστορικό της συνομιλίας και να υποστηρίζει συνεκτικές απαντήσεις σε διαδοχικές ερωτήσεις, διατηρώντας ταυτόχρονα την αξιοπιστία της διαδικασίας.



Σχήμα 1: Architectural Production Diagram



Σχήμα 2: Architectural Flow Diagram

Συμπεράσματα

Η ενασχόληση με τις agentic αρχιτεκτονικές και τη χρήση του LangGraph αποτέλεσε το πιο ενδιαφέρον κομμάτι του έργου, καθώς επέτρεψε την ανάπτυξη ενός συστήματος που δεν βασίζεται σε μία απλή κλήση ενός LLM αλλά ακολουθεί συγκεκριμένη διαδικασία λήψης αποφάσεων.

Αν ξεκινούσα την ανάπτυξη του έργου από την αρχή, θα αφιέρωνα περισσότερο χρόνο στον αρχικό σχεδιασμό της αρχιτεκτονικής και στη διαμόρφωση της δομής του συστήματος πριν ξεκινήσει η υλοποίηση. Κατά τη διάρκεια της ανάπτυξης προέκυψαν νέες απαιτήσεις, όπως η διαχείριση της μνήμης συνομιλιών και η καλύτερη οργάνωση των επιμέρους λειτουργιών του agent. Αυτές οι αλλαγές οδήγησαν σε αναδιαρθρώσεις του κώδικα, οι οποίες θα μπορούσαν να είχαν περιοριστεί με έναν πιο ολοκληρωμένο αρχικό σχεδιασμό. Επιπρόσθετα, θα αξιολογούσα και μεγαλύτερα ή πιο εξειδικευμένα γλωσσικά μοντέλα, ώστε να συγκρίνω την ποιότητα των απαντήσεων και την απόδοσή τους σε σύνθετα σενάρια.

Μελλοντικές Προσθήκες

Αν και το εργαλείο εξυπηρετεί τον άμεσο σκοπό του, υπάρχουν αρκετές δυνατότητες περαιτέρω εξέλιξης οι οποίες θα το καθιστούσαν ακόμη πιο αποδοτικό. Για παράδειγμα, η υλοποίηση ενός συστήματος αυθεντικοποίησης, θα συνέβαλε ώστε κάθε χρήστης να διαθέτει τη δική του προσωποποιημένη εμπειρία. Παράλληλα, η δημιουργία μιας βάσης δεδομένων για την αποθήκευση του ιστορικού συνομιλιών θα διατηρούσε το πλαίσιο μεταξύ διαφορετικών συνεδριών και θα βελτιώνει τη συνολική εμπειρία χρήσης. Επιπλέον, η δυνατότητα προσθήκης νέων εγγράφων πολιτικής από κάποιον διαχειριστή μέσω του συστήματος διεπαφής, θα επέτρεπε στον βοηθό να παραμένει συνεχώς ενημερωμένος και να παρέχει απαντήσεις βασισμένες στις πιο πρόσφατες πολιτικές της εταιρείας.

Τέλος, είναι αναγκαίο να αναφερθεί πως η τρέχουσα υλοποίηση χρησιμοποιεί την τοπική σειριοποίηση FAISS του LangChain, η οποία αποθηκεύει τα μεταδεδομένα των εγγράφων σε ένα αρχείο pickle. Καθώς ο δείκτης διανυσμάτων δημιουργείται και χρησιμοποιείται αποκλειστικά μέσα στο αξιόπιστο περιβάλλον της εφαρμογής, η ενεργοποίηση της επιλογής του επικίνδυνου deserialization είναι αποδεκτή για αυτό το proof of concept. Σε μία παραγωγική υλοποίηση, αυτός ο μηχανισμός θα πρέπει να αντικατασταθεί με μια πιο ασφαλή προσέγγιση, όπως η αποθήκευση των μεταδεδομένων σε ένα αρχείο JSON ή σε μια σχεσιακή βάση δεδομένων (π.χ. Qdrant ή Pinecone). Με αυτόν τον τρόπο, εξαλείφεται η ανάγκη για deserialization αυθαίρετων αρχείων pickle, μειώνοντας τον κίνδυνο εκτέλεσης κακόβουλου κώδικα.